HybridSN 高光谱图像分类实验报告

实验设置

Pavia University 原始数据尺寸为 610×340×103，含 42776 个有标签像元、9 个地物类别。采用 StandardScaler 与 PCA（30 维）预处理，11×11 空间 Patch，按类别分层以 10% 像元训练、其余测试；HybridSN 使用 3D 卷积提取光谱-空间特征并接 2D 卷积分类，训练 8 轮，批大小 16

主实验结果

OA	AA	Kappa
0.9902	0.9893	0.9871

混淆矩阵和逐类精度见配套图像与 metrics.json。OA 为整体精度，AA 为 9 类召回率的宏平均，Kappa 衡量扣除随机一致性后的分类一致程度。

空间分布分析

生成的预测图是覆盖整幅影像的，Ground Truth 中没有标注的区域也一并做了预测。GT 图上黑色的部分，只表示该像元没有人工标签，不能据此判定它属于哪一种地物；同样，预测图在这些位置上的输出也不纳入测试精度，因为那里没有参考标签可比。从标注数量上看，真实标注中像元最多的类别是 Meadows，18649 个；预测图中最多的也是 Meadows，49239 个。接着是空间上的表现。空间上成片而且边界清楚的区域，模型比较容易借助 Patch 的邻域信息保持类别一致；但在道路、草地、屋顶这些地物的交界处，混合像元同时包含多种光谱响应，容易沿边界形成细碎的错分。另外，较小或者狭长的地物在一块 Patch 里只占一部分，模型容易被周围占比更高的类别带偏；阴影、裸土、沥青以及深色屋顶之间光谱相似，也会进一步加重混淆。再看逐类精度。本次测试集中，逐类召回率最低的三类是：Self-Blocking Bricks 95.6%、Asphalt 97.0%、Trees 98.9%。混淆矩阵中数量较多的错分方向为：Self-Blocking Bricks 被分成 Gravel，135 个；Asphalt 被分成 Shadows，89 个；Asphalt 被分成 Bitumen，87 个。针对这些现象，我在结果判读上把握两条：如果预测图中某一类的斑块明显扩大、而召回率并不高，就要去检查这一类的精确率以及混淆矩阵中对应的那一列；如果斑块比较破碎、召回率也偏低，则优先检查这一类的训练样本数量，以及它与周边类别之间的混淆情况。指标方面，OA 是汇总所有测试像元计算的，可能被大类主导；AA 对九类召回率做等权平均，因此更能显示小类的表现；Kappa 则补偿了随机一致性的部分。所以我在阅读结果时，是把这三个指标和混淆矩阵、空间图放在一起判断的，不会仅凭总体精度就宣称所有类别都分类良好。最后说明实验条件。目前还是一个快速实验，训练样本比例、训练轮数和模型容量都受运行时间约束，因此边界噪声和少数类的误分是这次误差分析的重点。下一步我准备增大训练样本、增加训练轮数，然后重新生成全图、重新计算指标，再与改动之前的实测结果做对比。

对比与消融实验

设置	训练比例	PCA 波段	Patch	轮数	OA	AA	Kappa
comparison_baseline_4ep	10%	30	11	4	0.9970	0.9944	0.9960
train_ratio_5pct	5%	30	11	4	0.9822	0.9744	0.9764
pca_bands_15	10%	15	11	4	0.9916	0.9848	0.9888
patch_size_7	10%	30	7	4	0.9875	0.9792	0.9834

为控制训练轮数影响，以下差值均相对同样训练 4 轮的基准（OA 0.9970、AA 0.9944、Kappa 0.9960）计算。训练比例降至 5%：OA -0.0148、AA -0.0200、Kappa -0.0196。PCA 降至 15 维：OA -0.0054、AA -0.0096、Kappa -0.0072。Patch 缩至 7×7：OA -0.0095、AA -0.0152、Kappa -0.0126。这些差值来自同一随机种子和分层划分设置，但参数间仍可能有训练随机性；主实验 8 轮指标另列，不与 4 轮对照直接混作单变量差异。